

머신러닝 기업신용평가모형의 설명가능성(XAI/SHAP)과 금융당국 AI 검증체계 대응

모형 방법론 × 규제/감독 동향 | 2026-08-17 | NICE평가정보 컨설팅사업본부 심층 학습자료

핵심 요약 (TL;DR)

- ① XGBoost 등 트리 기반 앙상블모형은 로지스틱 회귀 대비 판별력(AUC·Gini)이 우수하지만 '블랙박스' 문제로 은행 내부통제·감독규제상 설명의무를 충족하기 어려웠으며, SHAP(SHapley Additive exPlanations)이 게임이론 기반 공리(Local Accuracy·Missingness·Consistency)를 만족하는 사실상 표준 해법으로 자리잡았다.
- ② 금융위원회는 2023년 4월 「AI 기반 신용평가모형 검증체계」를 마련해 데이터 관리, 알고리즘·변수 선정의 합리성, 통계적 유의성, 소비자 설명가능성 4대 축으로 개인사업자·개인신용평가회사의 AI 모형을 검증 중이며, 기업신용평가(CSS) 영역으로 확대 적용될 가능성에 대비해야 한다.
- ③ Moody's·S&P·Global 등 해외 신용평가사는 생성형AI를 등급 산정 자체가 아닌 리서치·요약 보조 도구로 한정 투입하는 'AI-보조, 인간-판단' 원칙을 유지하고 있어, 국내 은행·평가사 컨설팅 시 동일한 거버넌스 설계가 유효한 벤치마크가 된다.

1. 배경/맥락 — 왜 지금 이 주제가 중요한가

은행의 기업신용평가(CSS: Corporate Credit Scoring) 모형은 오랫동안 로지스틱 회귀 기반 스코어카드를 중심으로 운영되어 왔다. 그러나 최근 수년간 판별력 제고를 위해 XGBoost·LightGBM·랜덤포레스트 등 트리 기반 앙상블모형을 채권 스코어링, 조기경보, 부도예측(PD) 영역에 시범 도입하는 은행·평가사가 늘고 있다. 문제는 이러한 머신러닝 모형이 예측력은 높이지만, 개별 차주에 대한 등급·점수 산출 근거를 사람이 직관적으로 설명하기 어렵다는 점이다.

이는 단순한 기술적 이슈가 아니라 세 갈래의 규제 압력과 맞물린다. 첫째, 금융위원회·금융감독원은 「금융분야 AI 가이드라인」과 「AI 기반 신용평가모형 검증체계」를 통해 AI 활용 신용평가모형에 대해 소비자·감독당국에 대한 설명가능성을 명시적으로 요구하고 있다. 둘째, IFRS9 및 바젤 체계 하에서 PD 모형은 정기검증·모형위험관리(MRM) 절차상 변수 기여도와 등급 변동 원인을 문서화해야 한다. 셋째, 여신심사 과정에서 차주·영업점이 '왜 이 등급인가'를 요구할 때 은행이 합리적으로 답변하지 못하면 민원·소송 리스크로 이어진다. 따라서 SHAP과 같은 설명가능AI(XAI) 기법을 CSS 모형 고도화 프로젝트에 어떻게 내재화할 것인가는 2026년 현재 국내 은행권 모형개선 컨설팅에서 가장 자주 등장하는 요구사항 중 하나가 되었다.

2. 핵심 개념 설명 — 정의·이론적 배경·방법론

2.1 왜 트리 기반 앙상블(XGBoost)인가

XGBoost(eXtreme Gradient Boosting)는 다수의 얇은 의사결정트리를 순차적으로 학습시켜 잔차를 보정하는 그래디언트 부스팅 계열 알고리즘이다. 비선형 관계와 변수 간 상호작용(예: 매출채권회전율×업종더미)을 자동으로 포착하기 때문에, 재무비율 간 관계가 업종·기업 규모별로 상이한 기업신용평가 데이터에서 로지스틱 회귀 대비 AUC·Gini 기준 3~8%p 내외의 판별력 개선이 국내외 다수 연구에서 보고되고 있다. 다만 개별 트리 수백~수천 개의 앙상블 결과이므로, '왜 이 기업이 이 점수를 받았는가'를 계수 하나로 설명할 수 없다.

2.2 SHAP(SHapley Additive exPlanations)의 원리

SHAP은 협조적 게임이론의 샐플리 값(Shapley value)을 기계학습 예측에 적용한 기법으로, 각 입력변수(재무비율 등)가 모형의 기준 예측값(base value) 대비 개별 예측치를 얼마나, 어느 방향으로 밀어올렸는지를 가법적으로 분해한다. 핵심은 다음 네 가지 공리를 동시에 만족하는 사실상 유일한 모형-불가지론적(model-agnostic) 기법이라는 점이다.

- Local Accuracy(국소 정확성): 개별 변수 기여도의 합이 실제 예측값과 정확히 일치 — 감독기관이 요구하는 '설명의 완전성'과 대응
- Missingness(결측 일관성): 모형에 사용되지 않은 변수의 기여도는 0 — '유형 변수 기여' 방지 요건과 대응
- Consistency(일관성): 변수의 실제 한계기여도가 커지면 SHAP 값도 커짐 — 단조성(monotonicity) 요건과 대응
- Efficiency(효율성): 전체 기여도 분해가 잔차 없이 완결 — 모형 문서화의 '제로-잔차 분해' 요건과 대응

TreeSHAP 알고리즘은 트리 구조를 직접 활용해 다항시간 내 정확한 SHAP 값을 계산할 수 있어, XGBoost·LightGBM·랜덤포레스트 등 트리 기반 CSS 모형에 실무적으로 가장 널리 적용된다. 국소적으로는 개별 차주의 등급 산출 사유를, 전역적으로는 변수 중요도 순위(summary plot)·부분의존도(dependence plot)를 통해 모형 전체의 논리 구조를 제시할 수 있다.

2.3 TTC vs PIT, 그리고 XAI 도입 시 등급철학과의 정합성

은행 CSS는 전통적으로 경기순환 전체를 반영해 등급 변동성을 낮추는 TTC(Through-The-Cycle) 철학과, 현재 시점 정보를 즉각 반영하는 PIT(Point-In-Time) 철학 사이에서 설계된다. 머신러닝 모형은 데이터 패턴에 민감하게 반응하는 특성상 PIT에 가까운 등급 변동성을 보이는 경향이 있어, IFRS9의 12개월/전체기간 기대손실(ECL) 산출을 위한 PD 커브와의 정합성 검증이 별도로 필요하다. 이때도 SHAP은 '경기변수(거시지표)'가 등급 변동에 기여한 비중'과 '기업 고유 재무변수 기여 비중'을 분리해 제시함으로써, TTC/PIT 혼합설계의 근거자료로 활용될 수 있다.

3. 국내외 실무 사례

3.1 국내: 금융위원회 「AI 기반 신용평가모형 검증체계」

금융위원회는 2023년 4월 18일 「AI 기반 신용평가모형 검증체계」 및 「금융분야 AI 보안 가이드라인」을 마련했다. 검증체계는 ①신용정보회사의 데이터 관리 적정성, ②알고리즘·변수 선정의 합리성, ③모형의 통계적 유의성, ④금융소비자에 대한 모형·평가결과 설명가능성 네 축으로 구성되며, 개인신용평가체계 검증위원회가 개인사업자신용평가회사(CB사)의 AI 모형을 시작으로 순차 검증을 수행 중이다. 아직 기업(법인)신용평가 영역까지 명시적으로 확대되지는 않았으나, 가계신용→개인사업자신용 순으로 검증 범위가 확대된 전례를 볼 때 은행권 기업여신 CSS 모형에도 유사한 4대 축 요구가 준용될 가능성에 선제 대응하는 것이 바람직하다.

3.2 해외: Moody's·S&P; Global의 'AI-보조, 인간-판단' 원칙

S&P; Global은 2025년 5월 RatingsDirect®·Capital IQ Pro에 생성형AI 도구 'CreditCompanion™'을 탑재했다. 이는 LLM과 맞춤형 RAG(검색증강생성)를 활용해 방대한 리서치 자료를 검색·요약하고 기준에 부합하는 기업 리스트를 생성하는 등 애널리스트의 리서치 업무 시간을 절감하는 데 초점을 두며, 등급 산정 자체는 여전히 애널리스트 위원회의 판단 영역으로 남겨둔다. Moody's 또한 자사 데이터와 결합한 생성형AI 에이전트를 리서치·포트폴리오 분석에 투입하되, '책임 있는 AI(Responsible GenAI)'를 표방하며 등급 판정 프로세스와는 분리하고 있다. 두 회사 모두 AI를 정보처리·설명보조 계층에 두고, 최종 신용판단은 인간 애널리스트·위원회가 담당하는 구조를 유지함으로써 규제 리스크와 평판 리스크를 관리하고 있다는 점이 국내 컨설팅에 주는 시사점이 크다.

3.3 국내 CB사·평가사 동향

NICE평가정보를 포함한 국내 신용정보회사들은 그룹 차원에서 AI 기반 신용평가모형 연구개발을 확대하고 있으며, 계열 데이터회사와의 데이터 공유 체계를 통해 대안데이터(카드매출, 세금계산서 등)를 결합한 모형 고도화를

추진하고 있다. 국내 학계에서도 2010~2024년 국내 기업 신용등급 데이터를 활용해 Random Forest·XGBoost·CatBoost의 변수중요도를 비교하고, SHAP을 적용해 재무변수의 부도확률 기여도를 해석한 연구들이 다수 발표되며 실무 적용의 이론적 기반을 뒷받침하고 있다.

4. 최신 동향 (최근 1개월 우선)

2026년 7~8월 동향을 중심으로 살펴보면, 신용평가업 자체가 AI로 인해 재편되는 신호가 감지된다.

- Moody's, AI 투자궤 신용리스크 경고 (2026-07-24, CNBC): Moody's는 아마존·메타·알파벳 등 빅테크의 '전례 없는(unprecedented)' AI 설비투자 확대가 해당 기업들의 신용도(credit quality)에 부담 요인이 될 수 있다고 경고했다. AI가 피평가 대상 기업의 리스크 요인 자체로 부상하고 있음을 보여주는 사례로, 향후 CSS 모형의 산업/거시 변수 셋에 'AI 투자 익스포저' 관련 지표 반영 여부를 검토할 필요가 있다.
- 신용평가사 밸류에이션의 AI발 분화 (2026-06-08, Forbes): 투자자들이 Moody's·S&P·Global을 '등급산정 사업'과 '데이터·분석 사업(AI 경쟁 노출)'으로 분리해 평가하기 시작했다는 분석이 제기됐다. 이는 신용평가사의 핵심 경쟁력이 여전히 '등급 판단의 신뢰성'에 있으며, AI는 이를 보조하는 효율화 도구로 포지셔닝되고 있음을 시사한다.
- SHARC: 규제자본(ICAAP/CCAR)을 위한 SHAP 프레임워크 (2026, arXiv): SHAP을 ICAAP·CCAR 등 규제자본 산출용 리스크모형에 구조적으로 적용하는 'SHARC' 프레임워크가 발표됐다. SHAP의 4대 공리를 감독당국이 요구하는 모형 문서화 요건(완전성·무유령기여·단조성·잔차없는 분해)과 1:1로 대응시킨 점이 특징이며, 국내 PD모형 정기검증 보고서 설계에 참고할 만한 구조다.
- 인터넷전문은행 바젤III 전면 적용 (2026년~): 인터넷전문은행에 대한 바젤III 최종안이 2026년부터 전면 시행됨에 따라, 신용리스크 산출체계 전반(표준방법·내부등급법)의 적합성 재검증 수요가 발생하고 있다. 중소기업 대출 및 일부 기업대출의 위험가중치·부도시손실률(LGD) 하향 조정이 반영되며, CSS 모형 등급·위험가중치 매핑 재검증이 컨설팅 수요로 이어질 전망이다.

5. 컨설팅 실무 시사점

프로젝트·제안서 작성 시 아래 관점을 구조화해 활용할 수 있다.

- 제안서 차별화 포인트: '판별력 개선(AUC 제고)'만을 어필하는 제안은 더 이상 차별화 요소가 아니다. SHAP 기반 설명가능성 체계를 '금융위 AI 신용평가모형 검증체계 4대 축'에 대응시켜 설계·검증·문서화까지 패키지로 제시하는 것이 은행 리스크관리부서·검사대응팀에 설득력을 갖는다.
- 모형위험관리(MRM) 문서 표준화: 개별 차주 단위 SHAP force plot과 모형 전체 단위 summary plot을 정기검증보고서·이사회보고자료에 표준 산출물로 내재화하는 템플릿을 제안 범위에 포함시킨다.
- 영업점·여신담당자 설명 도구화: SHAP 값을 영업점 심사역이 이해할 수 있는 자연어 설명(예: '부채비율 상승이 이번 등급 하락의 40%를 설명')으로 변환하는 후처리 모듈은 현업 채택률을 크게 높이는 실질적 부가가치가 된다.
- TTC/PIT 적합성 검증 결합 제안: XAI 도입 프로젝트를 IFRS9 ECL·바젤 내부등급법 적합성 재검증 프로젝트와 번들링하면, 별도 과제로 발주되던 두 영역을 하나의 통합 컨설팅으로 확장할 수 있다.
- 거버넌스 벤치마크 제시: Moody's·S&P의 'AI·보조, 인간·판단' 원칙을 국내 은행 여신심의위원회 구조에 이식하는 거버넌스 설계(AI 산출 등급에 대한 인간 검토·override 로그화 등)를 제안서의 리스크관리 섹션에 포함시킨다.

6. 참고자료

아래 자료는 본 보고서 작성을 위해 웹 검색으로 확인한 출처이며, 추가 학습 시 참고할 수 있다.

구분	자료명 / 출처	링크
국내 규제	금융위원회, 「AI 기반 신용평가모형 검증체계」 및 「금융분야 AI 보안 가이드라인」 보도자료 (2023.4.18)	fsc.go.kr/po010101/79825
국내 언론	법률신문, "금융위원회, 「AI 기반 신용평가모형 검증체계」 및 「금융분야 AI 보안 가이드라인」 마련"	lawtimes.co.kr/LawFirm-NewsLetter/187302
해외 동향	CNBC, "Moody's says 'unprecedented' AI spending threatens credit quality of Amazon, Meta, Alphabet" (2026.7.24)	cnbc.com/2026/07/24
해외 동향	Forbes, "AI Splits How Investors Value The Credit-Ratings Giants" (2026.6.8)	forbes.com/sites/daraabasiita/2026/06/08
업계 사례	S&P; Global, "S&P; Global Introduces CreditCompanion™, Enhancing RatingsDirect®" 보도자료 (2025.5.21)	press.spglobal.com
업계 사례	Moody's, "Digital economy 2026 executive summaries: Artificial intelligence, digital finance..."	moodys.com/web/en/us/insights/credit-risk/outlooks
학술 자료	SHARC: SHAP-Based Interpretability in Machine Learning Risk Models for Regulatory Capital under ICAAP and CCAR (arXiv, 2026)	arxiv.org/pdf/2607.05484
학술 자료	A novel framework for enhancing transparency in credit scoring: Leveraging Shapley values for interpretable credit scorecards (PMC)	pmc.ncbi.nlm.nih.gov/articles/PMC11318906
국내 학술	설명 가능한 AI 기술을 활용한 신용평가 모형에 대한 연구, 한국데이터정보과학회지 (DBpia)	dbpia.co.kr/journal/articleDetail?nodeId=NODE10542538
국내 학술	머신러닝을 활용한 기업 신용평가모형 및 주요 재무변수 분석 (KCI)	kci.go.kr ... ART003234104
국내 규제	바젤Ⅲ 최종안 조기시행 및 인터넷전문은행 단계적 적용 관련 보도자료, KDI 경제정보센터	ieec.kdi.re.kr/policy/materialView.do?num=202242

※ 상기 국내 CB사·평가사(3.3절) 관련 서술 및 일부 방법론 설명(2절)은 공개된 웹 검색 결과가 제한적인 부분에 대해 컨설팅 도메인 배경지식을 결합해 작성하였다. 특정 기관의 내부 모형 사양이나 미공개 수치를 인용한 것은 아니며, 실제 프로젝트 적용 시에는 해당 기관 공식 발표자료 및 최신 감독규정 원문을 재확인할 것을 권고한다.

본 자료는 NICE평가정보 컨설팅사업본부 내부 학습 목적으로 작성되었으며, 대외 배포 시 최신 규정 및 원출처 확인이 필요합니다.