

머신러닝 기반 기업신용평가모형의 설명가능성(XAI·SHAP) 확보 전략

인공지능기본법 시행과 「AI 기반 신용평가모형 검증체계」 대응을 중심으로

작성일: 2026-09-21

NICE평가정보 컨설팅사업본부 · 기업신용평가모형(CSS) 개선 컨설팅 참고자료

핵심 요약 (TL;DR)

- 2026.1.22 인공지능기본법 시행으로 은행·신용정보사의 AI 기반 신용평가모형은 “고영향 AI”로 분류되어 **설명 의무**가 법적 요건이 되었고, 금융위 통합 AI 가이드라인도 2026.6.22 시행을 앞두고 있다.
- SHAP은 규제 대응 설명가능성(XAI)의 사실상 표준이 되었지만, **포트폴리오 비불변성(portfolio invariance 결여)**과 **변수 순위 불안정성**이라는 한계가 학계·실무에서 반복 지적되고 있어, 단순 도입이 아닌 안정성 검증 절차가 필요하다.
- 컨설팅 관점에서는 “SHAP 적용” 자체보다 **모형 거버넌스(정기검증·PSI·설명 재현성) 안에 XAI를 편입시키는 설계**가 은행 제안서·과업의 핵심 차별화 포인트가 된다.

1 배경/맥락: 왜 지금 이 주제가 중요한가

국내 은행 및 신용정보사의 기업신용평가모형(CSS)은 전통적으로 로지스틱 회귀 기반의 TTC(Through-The-Cycle) 등급체계를 근간으로 발전해 왔다. 그러나 최근 수년간 XGBoost·LightGBM 등 트리 기반 앙상블 모형, 나아가 TabNet과 같은 딥러닝 기반 정형데이터 모형이 판별력(AUC·KS·Gini) 개선을 목적으로 시범 도입되거나 하이브리드 형태(로지스틱 스코어카드 + ML 보정)로 실무에 적용되고 있다. 문제는 판별력 향상과 설명가능성이 상충 관계(trade-off)에 있다는 점이다.

2026년은 이 문제가 “선택”에서 “의무”로 전환되는 분기점이다. 2026년 1월 22일 시행된 **인공지능 발전과 신뢰 기반 조성 등에 관한 기본법(AI기본법)**은 이용자가 AI의 최종 결과, 주요 판단 기준, 학습데이터 개요를 이해할 수 있도록 설명 방법을 마련할 의무를 부과했으며, 신용평가·여신심사와 같이 개인·기업의 권리의무에 중대한 영향을 미치는 AI 시스템은 “고영향 AI”로 분류된다. 여기에 금융위원회가 기존 3개 금융분야 AI 가이드라인을 통합·개정한 **「금융분야 AI 가이드라인」**이 2026년 6월 22일 시행을 앞두고 있어, 은행권 CSS 고도화 프로젝트는 이제 “판별력 개선”과 “설명가능성·검증가능성 확보”를 동시에 만족시켜야 하는 이중 과제에 직면했다. 이는 컨설팅사 입장에서 신규 제안 및 기존 계약 범위 확대(설명가능성 모듈, 정기검증 고도화)의 직접적 기회 요인이기도 하다.

2 핵심 개념 설명: 정의, 이론적 배경, 방법론

2.1 XAI와 SHAP의 이론적 기초

설명가능한 AI(XAI)는 모형이 산출한 결과의 근거(주요 변수, 판단 기준, 기여도)를 사람이 이해할 수 있는 형태로 제시하는 기법·프로세스를 총칭한다. 신용평가 영역에서 가장 널리 쓰이는 기법은 **SHAP(Shapley Additive exPlanations)**으로, 게임이론의 Shapley Value 개념을 차용하여 개별 예측값에 대한 각 변수의 기여도를 산출한다. SHAP이 업계 표준으로 자리잡은 이유는 아래 네 가지 공리(axiom)를 동시에 만족하는 사실상 유일한 모형-불가지론적(model-agnostic) 기법이기 때문이다.

공리	의미	규제 대응 관점 의의
Local Accuracy	개별 기여도의 합이 실제 예측값과 정확히 일치	감독당국·민원인에 대한 수치적 정합성 설명 가능
Missingness	모형에 사용되지 않은 변수는 기여도 0	불필요한 변수 오귀속 방지
Consistency	변수의 실제 영향력이 커지면 기여도도 커짐	등급 상승·하락 사유의 논리적 일관성 확보
Efficiency	전체 기여도 합 = 예측값 - 기준값(base value)	감사(audit) 추적 시 수치 재현 가능

실무에서는 트리 기반 모형(XGBoost, Random Forest 등)에 최적화된 **TreeSHAP**이 계산 효율성 때문에 주로 쓰이며, 딥러닝 계열은 KernelSHAP·DeepSHAP 또는 애초에 해석가능성을 내장한 **TabNet**(어텐션 기반 변수 선택 구조)이 대안으로 제시된다. LIME(Local Interpretable Model-agnostic Explanations)은 국지적 선형 근사를 사용하는 보조 기법으로 일부 논문에서 SHAP과 병행 활용된다.

2.2 TTC vs PIT, 그리고 XAI의 접점

기업신용평가에서 TTC(경기순환 전 구간 평균 위험을 반영) 등급체계는 등급 변동성을 낮춰 여신정책·자본배분의 안정성을 제공하고, PIT(Point-In-Time) 등급체계는 현재 시점의 위험을 정확히 반영해 IFRS9 기대손실(ECL) 산정에 적합하다. ML 기반 모형은 비선형·상호작용 항을 다수 포함하므로 PIT 성격이 강해지는 경향이 있는데, 이 경우 SHAP 기여도 역시 시점별로 크게 요동칠 수 있어 “왜 지난 분기와 설명 사유가 달라졌는가”라는 감독당국·차주의 질의에 대응할 별도의 안정화 로직(예: 이동평균 기반 SHAP 스무딩, 구간별 앵커링)이 필요하다.

2.3 SHAP의 알려진 한계 - “도입”만으로는 부족한 이유

⚠ 실무 함정: 포트폴리오 비불변성(Non-portfolio-invariance)

SHAP 값은 해당 관측치가 속한 포트폴리오(학습·평가 데이터)의 특성 분포에 종속적이다. 즉 동일한 차주라도 포트폴리오 구성이 바뀌면(예: 산업 비중 변화, 표본 갱신) 설명 근거가 달라질 수 있다. 최근 연구(SHAP Stability in Credit Risk Management, 2026)는 예측력이 높은 변수는 SHAP 순위가 안정적인 반면, 중간 수준 기여 변수는 순위 변동성이 크다는 점을 실증했다. 이는 이의신청·감독검사 대응 시 “설명의 재현성” 문제로 직결된다.

또한 SHAP은 **사후적(post-hoc)** 근사 기법이므로 (1) 실제 모형 내부 연산과의 충실도(faithfulness) 격차, (2) 샘플링 기반 계산에 따른 실행 간 불안정성, (3) 상관관계일 뿐 인과관계를 보장하지 않는다는 한계가 병존한다. 따라서 컨설팅 산출물에서는 “SHAP을 적용했다”가 아니라 “**SHAP 안정성 검증(반복 샘플링, 부트스트랩 신뢰구간)까지 포함했다**”는 수준의 설계가 차별화 요소가 된다.

3 국내외 실무 사례

3.1 국내: 금융위 「AI 기반 신용평가모형 검증체계」

금융위원회는 신용정보회사가 (1) 데이터를 적절히 관리하는지, (2) 알고리즘·변수를 합리적으로 선정했는지, (3) 모형이 통계적으로 유의한지, (4) 금융소비자에게 모형과 결과를 충분히 설명할 수 있는지를 점검하는 검증체계를 마련해 신용정보회사(NICE평가정보 등)의 AI 모형 개발·검증 실무에 이미 반영되고 있다. 여기에 2026년 1분기 신용정보법 시행령·감독규정 개정 및 가명·익명처리 안내서 개정이 추가되어 대체데이터 활용 범위가 넓어지는 동시에 설명 책임도 강화되는 구도다.

3.2 국내: NICE평가정보의 기술 도입 동향

NICE평가정보는 2026년 3월 양자컴퓨팅 기반 AI 기업과 협력하여 금융이력부족자(Thin-filer) 대상 차세대 신용평가 모형 PoC(양자머신러닝, QML)를 추진 중이며, AI 기반 사업자 전용 신용평가 서비스도 출시한 바 있다. 이는 회사 차원에서 판별력 고도화와 설명가능성 확보라는 두 축을 동시에 추진하고 있음을 시사하며, 컨설팅 사업본부 입장에서는 사내 모형 개발 조직과의 XAI 방법론 정합성 확보가 대외 컨설팅 신뢰도에도 영향을 미치는 지점이다.

3.3 해외: Moody's · S&P Global · Fitch

기관	AI 활용 현황	비고
Moody's	생성형 AI 기반 신용분석 도구 자체 개발, 기업신용리스크 평가 모델링 방식 조정 중 “티핑포인트” 임박 시사	등급 산정 자체의 완전자동화는 아직 미실시
S&P Global	‘Credit Companion’ AI 리서치 도구 정식 출시(2026.5)	애널리스트 보조 도구 포지셔닝
Fitch Ratings	‘Fitch Genie’ 챗 솔루션 도입(2026.7)	데이터·분석 사업부에 AI 경쟁 노출 확대

해외 3대 신용평가사 공통적으로 “등급 산정 로직은 인간 애널리스트·위원회가 최종 결정하고, AI는 리서치·데이터 보조 도구로 한정”하는 신중한 태도를 취하고 있다. 이는 국내 은행권에도 시사하는 바가 크다 - CSS 고도화 시 ML 모형을 등급 자동 확정에 바로 투입하기보다 **1차 스코어링 + 2차 전문가 검토(human-in-the-loop)** 구조로 설계하는 것이 감독 대응 및 수용성 측면에서 안전하다.

4 최신 동향 (최근 1개월 우선)

- **[2026-06-22 시행 예정]** 금융위, 기존 「신용정보업감독규정」·「금융AI 가이드라인」 등 3개 지침을 통합한 「금융분야 AI 가이드라인」 시행. 금융회사가 보유 자원·AI 활용범위·서비스 위험수준을 고려해 적용 수준을 자율 결정하는 원칙기반(principle-based) 구조로 설계됨. (출처: 금융위원회 보도자료, 김·장 법률사무소 인사이트)
- **[2026-01-22 시행]** 인공지능기본법 시행 - 신용평가·여신심사 AI를 “고영향 AI”로 분류, 설명요구권 대응 의무 신설. 법적 요건(이해 가능한 설명)과 딥러닝 모형의 기술적 한계(수천 개 변수의 비선형 상호작용) 간 괴리가 실무 쟁점으로 부상. (출처: 국가법령정보센터, 신김 법률사무소 뉴스레터)
- **[2026년 상반기]** 학술 논문 “SHAP Stability in Credit Risk Management: A Case Study in Credit Card Default Model” 발표 - SHAP 변수 순위 불안정성을 실증 분석, 고기여 변수는 안정적이나 중간기여 변수는 변동성이 크다는 결론 제시. (출처: arXiv 2508.01851 / Risks 저널)
- **[2026년]** “SHARC” 프레임워크 발표 - ICAAP·CCAR 등 규제자본 산정 맥락에서 SHAP 기반 해석가능성을 표준화하려는 시도. 해외 은행권 규제자본 모형에도 XAI 표준화 논의가 본격화되고 있음을 보여줌. (출처: arXiv 2607.05484)
- **[2026-03]** NICE평가정보, 양자머신러닝(QML) 기반 Thin-filer 특화 신용평가모형 PoC 착수 발표. (출처: NICE평가정보 IR 보도자료)
- **[2026년]** Moody's, AI 대규모 설비투자(“unprecedented AI spending”)가 빅테크(Amazon·Meta·Alphabet 등)의 신용도에 미치는 영향을 경고 - AI가 피평가기업의 재무위험 요인이자 동시에 평가 도구 자체로 이중으로 작용하는 현상. (출처: CNBC, 2026-07-24)

5 컨설팅 실무 시사점

제안서·프로젝트 활용 포인트

1. **RFP 대응 키워드 선점**: 은행권 CSS 고도화 RFP에 “머신러닝 도입”과 함께 “AI기본법 대응”, “설명가능성 검증”이 필수 평가 항목으로 명시될 가능성이 높다. 제안서에 SHAP 단순 적용이 아닌 **SHAP 안정성 검증 절차(부트스트랩 신뢰구간, 포트폴리오 변화 시 재계산 트리거)**를 표준 산출물로 포함시킬 것.
2. **정기검증 체계 고도화 과업 확장**: 기존 AUC·Gini·KS·PSI·캘리브레이션 중심의 정기검증 프레임워크에 “**설명 재현성(Explanation Stability) 지표**”를 신규 검증 축으로 추가 제안 - 예: 분기별 SHAP Top-10 변수 순위의 Rank Correlation 모니터링, 설명 근거 변동 시 사전 정의된 조사 프로세스.
3. **Human-in-the-loop 거버넌스 설계**: 해외 3대 신용평가사가 등급 자동확정을 지양하고 애널리스트 최종 검토를 유지하는 사례를 벤치마킹, 국내 은행 여신심사 프로세스에도 “ML 1차 스코어링 + 심사역 2차 검토” 구조를 설계 표준으로 제시할 수 있다.
4. **대체데이터·XAI 결합 제안**: 카드매출·세금계산서 등 대체데이터 활용 확대(신용정보법 시행령 개정)와 맞물려, 새로운 변수를 모형에 추가할 때마다 SHAP 기반 “변수 기여도 사전·사후 비교 리포트”를 표준 산출물화하면 감독당국 설명 대응력과 프로젝트 부가가치를 동시에 높일 수 있다.
5. **내부 역량 포지셔닝**: 양자머신러닝(QML) 등 차세대 기법 PoC가 진행 중인 만큼, 컨설팅 조직도 “판별력 실험”뿐 아니라 “설명가능성·감독 대응 검증” 전문성을 별도 트랙으로 육성해 프로젝트 수주 시 기술 자문 범위를 넓힐 필요가 있다.

6 참고자료

- 금융위원회, 「AI 기반 신용평가모형 검증체계」 보도자료 - [fsc.go.kr/po010101/79825](https://www.fsc.go.kr/po010101/79825)
- 금융위원회, 「금융권 AX 가속화 및 금융분야 AI 가이드라인 개정안」 - [fsc.go.kr/no010101/87142](https://www.fsc.go.kr/no010101/87142)
- 인공지능 발전과 신뢰 기반 조성 등에 관한 기본법, 국가법령정보센터 - [law.go.kr](https://www.law.go.kr)
- **SHAP Stability in Credit Risk Management: A Case Study in Credit Card Default Model**, arXiv:2508.01851 (Risks 저널 게재)
- **SHARC: SHAP-Based Interpretability in ML Risk Models for Regulatory Capital under ICAAP and CCAR**, arXiv:2607.05484
- **On Machine Learning models explainability in the banking sector: the case of SHAP**, Journal of the Operational Research Society, Vol.76 No.12 (2025)
- 기업 신용평가 모형에 설명 가능한 AI 적용을 위한 TabNet 기반 프레임워크, 한국학술지인용색인(KCI)
- **Moody's, “Digital economy 2026 executive summaries: AI, digital finance, cyber risk”** - moodys.com
- **CNBC, “Moody’s says ‘unprecedented’ AI spending threatens credit quality of Amazon, Meta, Alphabet”** (2026-07-24)
- **NICE평가정보 IR 보도자료, “퀀텀 인텔리전스, 양자 AI 기반 신용평가 모델 PoC 추진”** - niceinfo.co.kr

※ 본 자료는 웹 검색(2026-09-21 기준 최신 공개 정보)을 기반으로 작성되었으며, 법령·가이드라인 시행일 등 세부 사항은 해당 기관 공식 발표를 통해 재확인이 필요합니다.