

로지스틱 회귀 계수는 왜 로그오즈비인가

— 결정경계의 기하, MLE의 수식, WOE/IV 실무를 하나로 연결하기

NICE평가정보 컨설팅사업본부 · 은행 기업신용평가모형(CSS) 개선 컨설팅 학습자료 · 2026-09-28

핵심 요약

- 로지스틱 회귀는 확률이 아니라 **로그오즈(log-odds)**에 대해 선형이다 — 이 한 문장이 기하(초평면), 수식(MLE), 실무(WOE)를 모두 관통한다.
- 재무변수를 WOE로 변환해 넣으면, 단일변수 포화모형에서 로지스틱 계수는 정확히 **-1**이 되는 대수적 관계가 성립한다 — 이는 우연이 아니라 WOE의 정의 자체가 로그오즈 차이이기 때문이다.
- 계수 크기·부호·IV값을 "그 자체로" 해석하면 다중공선성, 완전분리, 데이터 누수 같은 함정에 빠지기 쉽다 — 아래 숫자 예제와 실무 함정에서 구체적으로 확인한다.

1. 왜 알아야 하나 — 컨설팅 현장에서 이 개념이 등장하는 장면

은행 리스크관리부·여신심사부와의 모형 개발/검증 회의에서는 거의 매년 다음 세 가지 질문이 나온다. "이 변수의 계수 부호가 왜 이렇게 나왔는가", "WOE 변환을 왜 하는가, 원값을 그대로 넣으면 안 되는가", "이 모형이 등급을 나누는 기준(결정경계)은 통계적으로 무엇을 의미하는가". 이 세 질문에 답하려면 로지스틱 회귀를 **직관(로그오즈 공간의 선형성), 수식(최대우도추정, MLE), 기하(결정경계 초평면)** 세 층위에서 동시에 설명할 수 있어야 한다. 특히 기업신용평가(CSS) 재무모형은 지금도 대부분 로지스틱 회귀 + WOE 변환을 표준 엔진으로 사용하며, ML 모형(XGBoost 등)을 도입 하더라도 감독당국·모형위원회에 설명할 때는 결국 로지스틱 회귀의 언어(오즈비, 계수, 결정경계)로 환산해서 보고하는 경우가 많다. 따라서 이 개념은 신규 모형 개발뿐 아니라 **기존 모형의 계수를 검증·설명·재현**하는 모든 컨설팅 프로젝트의 기초 문법이다.

2. 직관적 설명 — 왜 "확률"이 아니라 "로그오즈"에 선형인가

부도확률 p 는 0과 1 사이로 제한된 값이다. 재무변수들의 선형결합($\beta_0 + \beta_1 x_1 + \dots$)은 원리적으로 $-\infty$ 부터 $+\infty$ 까지 어떤 값도 가질 수 있다. 이 둘을 직접 등식으로 연결하면(즉 $p = \beta_0 + \beta'x$ 로 두면) 우변이 조금만 커지거나 작아져도 좌변이 1을 넘거나 0보다 작아지는 모순이 생긴다. 그래서 **확률을 오즈(odds) = $p/(1-p)$ 로 바꾸고, 오즈에 로그를 취한 "로그오즈(logit)"**를 매개로 쓴다. 오즈는 0부터 $+\infty$, 로그오즈는 $-\infty$ 부터 $+\infty$ 의 범위를 가지므로 비로소 선형결합과 범위가 일치한다. 즉 로지스틱 회귀가 하는 일은 "확률의 선형모형"이 아니라 **"로그오즈의 선형모형"**이며, 이 로그오즈를 다시 시그모이드(sigmoid) 함수로 되돌려 확률로 해석하는 것뿐이다.

2-1. 수식 전개

기호를 다음과 같이 정의한다. $y_i \in \{0,1\}$ 은 기업 i 의 부도 여부(1 =부도/Bad, 0 =정상/Good), x_i 는 재무변수 벡터, $\beta = (\beta_0, \beta_1, \dots, \beta_k)$ 는 회귀계수, $p_i = P(y_i=1|x_i)$ 이다.

로짓(logit) 정의: $\text{logit}(p_i) = \ln(p_i / (1-p_i)) = \beta_0 + \beta'x_i$ (선형)

확률로 역변환(시그모이드): $p_i = 1 / (1 + \exp(-(\beta_0 + \beta'x_i)))$

계수 해석: β_j 는 "다른 변수를 고정했을 때, x_j 가 1단위 증가하면 로그오즈가 β_j 만큼 증가한다"는 뜻이며, $\exp(\beta_j)$ 는 **오즈비(odds ratio)** — x_j 가 1단위 증가할 때 부도 오즈가 몇 배가 되는지를 의미한다. "계수가 로그오즈비"라는 것은 바로 이 $\exp(\beta_j)$ =오즈비 관계에서 나온 표현이다.

파라미터 β 는 **최대우도추정(MLE)**으로 구한다. n 개 기업이 서로 독립이라고 가정하면 우도함수는:

$$L(\beta) = \prod_{i=1}^n p_i^{y_i} (1-p_i)^{1-y_i}$$

$$\text{로그우도: } \ell(\beta) = \sum_i [y_i \ln p_i + (1-y_i) \ln(1-p_i)]$$

$$\text{1차 조건(그래디언트): } \partial \ell / \partial \beta = \sum_i x_i (y_i - p_i) = X'(y-p) = 0$$

$$\text{2차 조건(헤시안): } \partial^2 \ell / \partial \beta \partial \beta' = -X'WX, W = \text{diag}(p_i(1-p_i))$$

그래디언트 식 $X'(y-p)=0$ 은 β 에 대해 비선형(p_i 가 β 의 비선형함수)이므로 대수적으로 풀리지 않고, **뉴턴-랩슨(Newton-Raphson) / IRLS(Iteratively Reweighted Least Squares)**로 반복 추정한다. 헤시안이 항상 음의 반정부호(negative semi-definite)이므로 로그우도는 오목함수(concave)이며, 이는 **전역 최적해가 유일하게 존재함**을 보장한다 — 로지스틱 회귀가 "국소최적에 빠질 위험 없이 항상 같은 해로 수렴하는" 안정적인 모형으로 평가받는 이유가 여기에 있다.

2-2. 기하적 해석 — 결정경계는 로그오즈 공간의 초평면

$\beta_0 + \beta'x=0$ 을 만족하는 x 의 집합은 로그오즈가 정확히 0, 즉 $p=0.5$ 인 지점들의 집합이며 이를 **결정경계 (decision boundary)**라 한다. 변수가 2개면 직선, 3개 이상이면 **초평면(hyperplane)**이 된다. 계수벡터 $\beta=(\beta_1, \dots, \beta_k)$ 는 이 초평면의 **법선벡터(normal vector)**이며, $\beta'x_i$ 의 값은 "기업 i 가 이 초평면으로부터 얼마나, 어느 방향으로 떨어져 있는가"를 나타낸다. β 와 같은 방향으로 멀어질수록 로그오즈(부도확률)가 커지고, 반대 방향으로 멀어질수록 로그오즈가 작아진다. 즉:

- **직관**(확률 대신 로그오즈를 쓴다) → **수식**(로그오즈=선형결합, MLE로 β 추정) → **기하**(β 는 초평면의 법선벡터, 결정경계는 $p=0.5$ 인 등고선)로 세 설명이 하나의 대상을 다른 각도에서 본 것임을 확인할 수 있다.

3. WOE/IV와 로지스틱 계수의 관계 — 대수적으로 정확히 증명되는 연결

재무비율을 구간(bin)으로 나누고 각 구간을 **WOE(Weight of Evidence)**로 치환하는 것은 CSS 재무모형의 표준 전처리다. WOE_j 는 구간 j 에서 "정상(Good) 비중"과 "부도(Bad) 비중"의 로그비율로 정의한다 (본 문서는 값이 클수록 안전한 방향으로 정의):

$$WOE_j = \ln((Good_j / Good_{\text{총}}) / (Bad_j / Bad_{\text{총}}))$$

이 식을 로그의 성질로 분해하면:

$$WOE_j = [\ln(Good_j) - \ln(Bad_j)] - [\ln(Good_{\text{총}}) - \ln(Bad_{\text{총}})] = -[\ln(Bad_j / Good_j) - \ln(Bad_{\text{총}} / Good_{\text{총}})] = -(\text{logit}_j - \text{logit}_{\text{평균}})$$

즉 **$WOE_j = \text{logit}_{\text{평균}} - \text{logit}_j$** (여기서 $\text{logit}_j = \ln(Bad_j / Good_j)$, target $y=1$ =부도 기준). 이 변수 하나만 구간별 더미로 넣은 "포화모형(saturated model)"에서는 각 구간의 예측 로짓이 그 구간의 경험적 로그오즈와 정확히 일치하므로, WOE를 연속변수로 넣은 단순 로지스틱 모형 $\text{logit}(p) = \beta_0 + \beta_1 \cdot WOE_j$ 은 **$\beta_0 = \text{logit}_{\text{평균}}$, $\beta_1 = -1$** 일 때 포화모형과 정확히 같아진다. 이것이 "WOE로 변환한 변수의 로지스틱 계수는 이론상 1(부호 정의에 따라 -1)에 가까워야 한다"는 실무 규칙의 수학적 근거다. 다변량 모형에서 계수가 여기서 벗어나는 정도는 다른 변수와의 정보 중복(다중공선성)이나 구간(bin)이 노이즈를 포함하고 있다는 신호로 해석한다.

IV(Information Value)는 이 WOE를 구간 비중으로 가중합산한 값으로, 변수 전체의 판별력을 하나의 숫자로 요약한다:

$$IV = \sum_j (\text{Good}_j / \text{Good}_{\text{총}} - \text{Bad}_j / \text{Bad}_{\text{총}}) \times \text{WOE}_j$$

4. 숫자 예제 — 가상 기업 포트폴리오의 이자보상배율(ICR) 변수

아래 수치는 계산 과정을 명확히 보이기 위해 설계한 가상 포트폴리오(기업 1,000개, 부도 100개=10%)이며, 실제 기업신용평가 포트폴리오의 부도율(통상 1~3%대)보다 높게 설정했다. 실제 데이터에서는 부도가 희소하므로 구간별 표본수가 훨씬 중요한 이슈가 된다(§ 5 참고).

이자보상배율(ICR) 구간	정상(Good)	부도(Bad)	%Good	%Bad	WOE	IV 기여분
ICR < 1 (이자도 못 총당)	60	40	6.7%	40.0%	-1.792	0.597
1 ≤ ICR < 3	170	30	18.9%	30.0%	-0.463	0.051
3 ≤ ICR < 6	280	20	31.1%	20.0%	0.442	0.049
ICR ≥ 6	390	10	43.3%	10.0%	1.466	0.489
합계	900	100	100%	100%	—	IV = 1.187

검증: 구간별 경험적 로짓 $\text{logit}_j = \ln(\text{Bad}_j / \text{Good}_j)$ 을 직접 계산하면 각각 -0.405, -1.735, -2.639, -3.664 이고, 전체 평균 $\text{logit}_{\text{평균}} = \ln(100/900) = -2.197$ 이다. § 3에서 증명한 $\text{WOE}_j = \text{logit}_{\text{평균}} - \text{logit}_j$ 을 적용하면 예를 들어 $\text{ICR} \geq 6$ 구간은 $-2.197 - (-3.664) = 1.466$ 으로, 표에서 직접 계산한 $\text{WOE}(1.466)$ 와 정확히 일치한다 — 이는 우연이 아니라 § 3의 대수적 관계 그 자체다.

스코어카드 점수로 환산. 실무에서는 로짓을 그대로 보여주지 않고, "PDO(Points to Double the Odds, 오즈가 2배가 되는 데 필요한 점수)"를 이용해 점수로 스케일링한다. 오즈를 정상(Good)/부도(Bad) 기준으로 정의하면:

$$\text{Score} = \text{Offset} + \text{Factor} \times \ln(\text{Odds}_{\text{Good}}), \quad \text{Factor} = \text{PDO} / \ln(2)$$

PDO=20점, 기준오즈 50:1에서 600점이 되도록 Offset을 정하면 $\text{Factor} = 20 / \ln 2 = 28.85$, $\text{Offset} = 600 - 28.85 \times \ln(50) = 600 - 112.8 = 487.2$ 이다. 이자보상배율 구간별 $\text{Odds}_{\text{Good}} = \text{Good}_j / \text{Bad}_j$ 를 대입하면:

구간	$\text{Odds}_{\text{Good}} (= \text{Good} / \text{Bad})$	$\ln(\text{Odds})$	스코어카드 점수
ICR < 1	1.50	0.405	499점
1 ≤ ICR < 3	5.67	1.735	537점
3 ≤ ICR < 6	14.00	2.639	563점
ICR ≥ 6	39.00	3.664	593점

가장 위험한 구간과 가장 안전한 구간 사이의 점수차는 약 **94점**이다. 이렇게 재무변수 하나의 WOE/IV 가 바로 스코어카드 점수차로 직결되므로, 컨설팅 과정에서 "이 변수를 모형에 넣으면 점수가 몇 점 갈리는가"를 숫자로 먼저 보여주는 것이 고객(은행) 실무진과의 논의를 훨씬 구체적으로 만든다.

5. 실무 함정과 오해

합정 1 — "계수 크기 = 변수 중요도"라는 오해. 회귀계수는 변수의 척도(scale)에 의존한다. 원값을 넣은 변수와 WOE로 변환한 변수의 계수는 크기가 전혀 다르므로, 계수만 보고 중요도를 비교하면 안 된다. 중요도 비교는 IV, 표준화계수, 또는 SHAP 등 스케일에 무관한 지표로 해야 한다.

합정 2 — "WOE 계수가 1이 아니면 모형이 잘못됐다"는 오해. § 3에서 본 -1 (또는 1) 관계는 *단일변수 포화모형*에서만 정확히 성립한다. 다변량 모형에서는 변수 간 정보 중복 때문에 계수가 자연스럽게 1에서 벗어난다. 실무에서 문제로 봐야 하는 경우는 **부호가 반대로 나오는 경우**(다중공선성 신호)이며, 크기가 1에서 다소 벗어난 것 자체는 정상이다.

합정 3 — 완전분리(complete/quasi separation). 어떤 구간에 부도(Bad)가 0이면 그 구간의 로짓은 $\ln(0/Good)=-\infty$ 로 발산하고, MLE 알고리즘이 수렴하지 않거나 계수가 비정상적으로 커진다. 표본이 작은 구간, 혹은 특정 산업·규모 구간에서 자주 발생하며, 최소 표본수 기준과 스무딩(라플라스 보정 등)이 필요하다.

합정 4 — IV가 너무 높으면 오히려 의심해야 한다. 본 예제의 $IV=1.187$ 처럼 실무 기준(통상 $0.3\sim 0.5$ 를 "강한 변수", 0.5 초과는 "의심 구간"으로 보는 Siddiqi식 관행)을 훌쩍 넘는 경우, 변수 정의 시점이 부도 판정 이후 정보를 포함하는 **데이터 누수(target leakage)**일 가능성부터 점검해야 한다. 개발 성능은 매우 좋아 보이지만 운영 시 급락하거나 검증 단계에서 지적받는 전형적 사례다.

합정 5 — 결정경계($p=0.5$)를 등급 컷오프와 혼동. 결정경계는 수학적으로 $p=0.5$ 인 지점일 뿐이며, 실제 기업 포트폴리오의 부도율은 $1\sim 5\%$ 수준이 흔하므로 실무 등급 컷오프는 훨씬 낮은 확률 구간에서 다단계로 설정된다. "이 모형의 결정경계가 곧 부도/정상을 나누는 실무 기준"이라는 설명은 고객에게 혼동을 줄 수 있다.

6. 현직자 수준 점검 질문

Q1. 로지스틱 회귀는 왜 확률이 아니라 로그오즈에 대해 선형인가?

A. 확률은 $[0,1]$ 로 제한되어 선형결합($-\infty\sim+\infty$)과 범위가 맞지 않는다. 오즈($p/(1-p)$)는 $[0,\infty)$, 로그오즈는 $(-\infty,\infty)$ 로 범위가 선형결합과 일치하므로 로그오즈를 매개로 선형모형을 세우고, 시그모이드로 확률로 되돌린다.

Q2. WOE로 변환한 변수의 로지스틱 계수가 1이 아니고 0.7이 나왔다. 문제인가?

A. 정상이다. 1 (또는 -1)은 단일변수 포화모형에서만 성립하는 이론값이며, 다변량 모형에서는 다른 변수와의 정보 중복으로 계수가 자연스럽게 이동한다. 부호가 반대로 나오는 경우에만 다중공선성을 의심한다.

Q3. IV가 1.2인 변수를 그대로 모형에 써도 되는가?

A. 아니다. 실무 관행상 $IV\ 0.5$ 초과는 "의심 구간"이며, 변수 정의가 부도 판정 이후 시점의 정보를 담고 있는 데이터 누수 여부를 먼저 점검해야 한다.

Q4. 결정경계(로짓=0)가 은행의 등급 컷오프와 같은 의미인가?

A. 아니다. 결정경계는 $p=0.5$ 라는 수학적 정의일 뿐이며, 실제 여신 포트폴리오의 등급 컷오프는 부도율이 훨씬 낮은 확률 구간에서 다단계로(예: 10등급) 설정된다.

Q5. 로지스틱 회귀의 MLE는 닫힌 해(closed form)로 구해지는가?

A. 아니다. 로그우도의 1차 조건 $X'(y-p)=0$ 이 β 에 대해 비선형이라 대수적으로 풀리지 않고, 뉴턴-랩슨(IRLS) 등 반복 알고리즘으로 수치적으로 추정한다. 다만 로그우도가 오목함수이므로 해는 유일하게 수렴한다.

7. 컨설팅 실무 시사점

① **제안서·개발보고서에서 로지스틱+WOE를 쓰는 이유를 설명할 때** — "선형이라 해석 가능, WOE 결합으로 비선형 관계를 반영하면서도 계수를 오즈비로 규제기관에 설명 가능, MLE의 오목성으로 항상 동일한 해로 수렴해 재현성이 보장된다"는 세 가지 근거를 제시할 수 있다.

② **모형 검증 회의에서** — "WOE 계수가 1(-1)에서 얼마나 벗어나는가"를 다중공선성 1차 스크리닝 지표로, "IV가 0.5를 넘는 변수가 있는가"를 데이터 누수 점검 체크리스트 항목으로 제안할 수 있다.

③ **스코어카드 재조정 프로젝트에서** — PDO/Offset 파라미터를 은행의 기존 여신정책(한도·금리 구간)에 맞춰 재산출하는 작업 자체가 "모형 개선"의 구체적 산출물이 되며, 본 문서의 숫자 예제(구간 하나로 94점 차이)처럼 "변수 하나의 재정의가 스코어에 몇 점의 영향을 주는지"를 정량적으로 제시하면 고객사의 의사결정을 훨씬 빠르게 만든다.

8. 참고자료

- Hosmer, D.W., Lemeshow, S., Sturdivant, R.X., *Applied Logistic Regression* (3rd ed.) — MLE 도출·로그우도의 오목성에 대한 표준 교과서 설명
- Siddiqi, N., *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring* — WOE/IV 정의, PDO 스코어카드 스케일링 실무 표준
- Statlect, "Logistic regression - Maximum likelihood estimation" — 로그우도·그래디언트 도출 참조:
<https://www.statlect.com/fundamentals-of-statistics/logistic-model-maximum-likelihood>
- UC San Diego CSE250B Lecture Notes, "Maximum Likelihood, Logistic Regression, and Stochastic Gradient Training" — MLE·그래디언트 수식 참조: <https://cseweb.ucsd.edu/~elkan/250B/logreg.pdf>
- ListenData, "Weight of Evidence (WOE) and Information Value (IV) Explained" — WOE/IV 정의 및 실무 임계치 참조:
<https://www.listendata.com/2015/03/weight-of-evidence-woe-and-information.html>
- ScorePlus, "Notes on Scorecard Scaling" — PDO/Offset/Factor 스코어카드 스케일링 공식 참조:
<https://www.scoreplus.info/assets/files/Scorecard%20Scaling%20-%20ScorePlus%20-%20May%202017.pdf>
- 숫자 예제(§ 4)의 포트폴리오 데이터는 계산 과정을 보기 위해 구성한 가상 데이터이며, 실제 관측치가 아니다.