WOE를 넣은 로지스틱 회귀의 계수는 왜 1에서 출발하고, 왜 1보다 작아지는가

— 베이즈 정리·MLE·기하로 연결하는 WOE/IV와 스코어카드 배점

트랙 A (통계·모형 이론 심층) · 2026-11-11 · NICE평가정보 컨설팅사업본부 학습자료

1. 핵심 요약

① 구간화 변수 하나만 쓰면 사후 로그오즈 = ln(G/B) + WOE 가 **항등식**이므로, WOE를 설명변수로 넣은 로지스틱 회귀의 MLE는 정확히 β=1, 절편=ln(G/B)이다.
② 변수가 여러 개면 β=1들의 합(나이브 베이즈)은 변수 간 중복 정보를 이중 계산한다. 로지스틱은 계수를 1보다 작게 줄여서 이 중복을 덜어낸다. 그래서 β_j는 "그 변수의 단변량 증거 중 다른 변수로 설명되지 않고 남는 몫"으로 읽힌다.
③ IV는 우량·불량 분포 사이 대칭 KL 발산(Jeffreys divergence)이다. 단변량 변별력의 척도이고, 다변량 모형에서의 기여도를 보장하지는 않는다. 계수가 0 근처이거나 음수로 나오면 공선성 신호다.

2. 왜 알아야 하나 — 실무에서 이 개념이 등장하는 장면

- **재무모형 개발 보고서의 변수선정표:** "IV 0.66인 이자보상배율이 다변량에서는 계수 0.71" 같은 결과를 고객 은행 모형위원회에 설명해야 한다. 계수가 1보다 작다는 사실 자체가 "변수끼리 겹친다"는 진단 정보다.
- **검증(정기검증·독립검증):** WOE 모형에서 음(−)의 계수가 나오면 배점 방향이 직관과 반대인 변수가 생긴다. 금감원 검사나 내부 검증에서 "설명 가능성" 지적을 받는 대표 사례다.
- **스코어카드 배점(Points) 산출:** 등급표의 점수는 β×WOE×Factor로 만들어진다. β의 의미를 모르면 PDO 조정이나 재보정 때 점수 체계를 잘못 바꾸게 된다.
- **표본 설계:** 부도 표본을 오버샘플링하면 WOE와 β는 그대로이고 절편만 바뀐다. 이 사실을 알아야 PD 캘리브레이션 단계를 올바르게 설계할 수 있다.

3. 직관 → 수식 → 기하

3.1 직관: WOE는 "이 구간에 속했다는 사실이 주는 증거의 양"

$WOE_i = \ln(\%Good_i / \%Bad_i)$는 구간 i가 우량 기업 집단에서 불량 기업 집단보다 얼마나 더 자주 나타나는지를 로그로 잰 값이다. 사전 로그오즈(전체 우량:불량 비율)에 이 증거를 **더하면** 그 구간의 사후 로그오즈가 된다. 베이즈 정리를 로그 공간에서 쓰면 곱셈이 덧셈이 되므로, WOE는 "로그오즈 단위로 환산한 변수"가 된다.

3.2 수식 ① — 단일 변수: 베이즈 정리에서 β=1이 나오는 이유

기호: $Y \in \{G(우량), B(불량)\}$, x = 구간 i, $g_i \cdot b_i$ = 구간 i의 우량·불량 기업 수, $G=\Sigma g_i$, $B=\Sigma b_i$, $f(x|G)=g_i/G$, $f(x|B)=b_i/B$

베이즈: $P(G|x)/P(B|x) = [P(G)/P(B)] \times [f(x|G)/f(x|B)]$
로그: $\ln odds(x_i) = \ln(G/B) + \ln[(g_i/G)/(b_i/B)] = \ln(G/B) + WOE_i \quad \cdots (\bigstar)$
검산: $\ln(G/B) + \ln(g_i B / b_i G) = \ln(g_i/b_i)$ ← 구간 i의 경험적 로그오즈 그 자체

로지스틱 모형 $\ln odds = \beta_0 + \beta_1 \cdot WOE_i$를 생각하자. $(\beta_0, \beta_1) = (\ln(G/B), 1)$을 넣으면 (★)에 따라 모든 구간에서 예측 우량확률 p_i가 실제 비율 $g_i/(g_i+b_i)$와 같아진다. 로그우도 $\ell(\beta)=\Sigma[y \cdot \ln p + (1-y)\ln(1-p)]$의 기울기(score)는

$$\partial \ell / \partial \beta_0 = \Sigma_n (y_n - p_n) = \Sigma_i [g_i - (g_i+b_i)p_i] = 0, \quad \partial \ell / \partial \beta_1 = \Sigma_i \, WOE_i \cdot [g_i - (g_i+b_i)p_i] = 0$$

각 구간 안에서 괄호가 0이므로 두 식이 모두 성립한다. 로지스틱 로그우도는 오목함수이므로 기울기가 0인 점은 유일한 최대점이다. 따라서 **MLE는 정확히 $\beta_1=1$, $\beta_0=\ln(G/B)$**이다(근사가 아니다). 이 결과는 Lund(2016)도 보고한다. 이 모형은 구간별 경험적 PD를 그대로 재현하는 포화 상태와 같다.

3.3 수식 ② — 다변량: 왜 β가 1보다 작아지나

두 변수의 결합 증거를 연쇄법칙으로 분해:
$\ln[f(x_1,x_2|G)/f(x_1,x_2|B)] = WOE_1(x_1) + WOE_{2|1}(x_2|x_1)$
$WOE_{2|1} = \ln[f(x_2|x_1,G)/f(x_2|x_1,B)]$ ← x_1을 이미 안 상태에서 x_2가 "추가로" 주는 증거

- 조건부 독립($X_1 \perp X_2 \mid Y$)이면 $WOE_{2|1} = WOE_2$ → ln odds = $\ln(G/B)+WOE_1+WOE_2$ (나이브 베이즈, β=1,1)
- 두 변수가 같은 기업 체력(수익성·부채상환력)을 공유하면 $|WOE_{2|1}| < |WOE_2|$ → 로지스틱 MLE가 $\beta_1, \beta_2 < 1$로 줄여서 근사

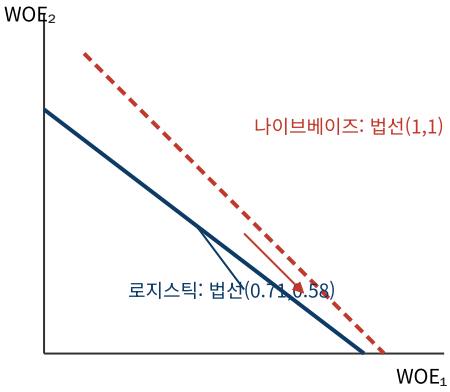
따라서 다변량 로지스틱은 "WOE 나이브 베이즈 + 계수로 중복 보정"인 **semi-naive Bayes**로 볼 수 있다(Larsen, Stitch Fix). $\beta_j \approx 0$이면 그 변수의 정보가 다른 변수들에 거의 다 들어 있다는 뜻이다. $\beta_j<0$은 억제효과(suppression) 때문에 생긴다. 상관이 높은 두 변수 중 하나가 다른 변수의 잡음을 상쇄하는 방향으로 쓰이는 경우로, 해석할 수 있는 신용 논리가 아니다.

3.4 수식 ③ — IV는 왜 "대칭 KL 발산"인가

$p_i = g_i/G$, $q_i = b_i/B$ 라 하면
$IV = \Sigma_i (p_i - q_i)\cdot\ln(p_i/q_i) = \Sigma\, p_i\ln(p_i/q_i) + \Sigma\, q_i\ln(q_i/p_i) = KL(G \parallel B) + KL(B \parallel G)$
각 항에서 (p_i-q_i)와 $\ln(p_i/q_i)$는 부호가 같으므로 항마다 ≥ 0 → IV $\geq$ 0. 0이 되는 것은 p=q(변별력 없음)일 때뿐

같은 식에서 G·B 대신 개발 시점·운영 시점 분포를 넣으면 PSI가 된다. IV와 PSI는 "같은 발산을 서로 다른 두 분포에 적용한 것"이다(Sudjianto & Burakov, 2025). 따라서 IV에도 PSI와 같은 약점이 있다. 구간을 잘게 나눌수록 커지고, 표본 수가 적으면 위로 편향된다.

3.5 기하적 해석 — WOE 공간에서의 결정경계



WOE로 변환하면 각 축이 "로그오즈 단위"로 맞춰진다. 이 평면에서 등PD선(같은 등급 경계)은 $\beta_1W_1+\beta_2W_2=c$인 직선(다변량에서는 초평면)이다. 나이브 베이즈는 법선 벡터를 (1,1)로 고정해서 모든 축의 증거를 같은 크기로 더한다. 로지스틱은 (i) 법선의 **방향을 회전**시켜 변수 간 상대 중요도를 다시 정하고, (ii) 법선의 **길이를 줄여** 상관된 축에서 증거가 이중으로 쌓이지 않게 한다. 법선이 짧아지면 같은 W 이동에 대해 로그오즈가 덜 움직인다. 즉 PD 분포가 극단으로 덜 퍼지고, 캘리브레이션이 개선된다.

4. 숫자 예제

4.1 단일 변수: 가상 외감기업 10,000개, 1년 부도 400개(4%)의 이자보상배율

이자보상배율	우량 g	불량 b	부도율	%G	%B	WOE	IV 기여	ln(g/b)
<1.0배	900	150	14.29%	9.38%	37.50%	−1.386	0.390	1.792
1.0~2.0	1,500	100	6.25%	15.63%	25.00%	−0.470	0.044	2.708
2.0~5.0	3,000	90	2.91%	31.25%	22.50%	0.329	0.029	3.507
5.0~10.0	2,200	40	1.79%	22.92%	10.00%	0.829	0.107	4.007
≥10.0	2,000	20	0.99%	20.83%	5.00%	1.427	0.226	4.605
합계	**9,600**	**400**	**4.00%**				**IV=0.796**	**ln(G/B)=3.178**

검산: 첫 구간 3.178 + (−1.386) = 1.792 = ln(900/150)이다. 모든 구간에서 "ln(G/B)+WOE = 경험적 로그오즈"가 성립하므로 로지스틱 적합 결과는 β_1=1.000, β_0=3.178이다. IV 0.80은 업계 관행 기준(<0.02 무의미, 0.1~0.3 중간, >0.3 강함, >0.5

과대 의심)에서 "의심" 구간에 해당한다. 이 정도로 높으면 부도 정의 시점과 재무제표 결산 시점이 겹쳐 사후 정보가 섞이지 않았는지 먼저 확인해야 한다.

4.2 두 변수: 상관된 재무비율이 계수를 줄이는 장면 (시뮬레이션)

설정: 기업 20,000개, 공통 기업체력 z~N(0,1). 이자보상배율·차입금의존도의 잠재값은 각각 0.8z + 0.6ε, PD는 logistic(−3.6 − 1.1z)로 생성(seed 7). 실현 부도 850개(4.25%). 이자보상배율 5구간, 차입금의존도 3구간으로 WOE를 산출하고, Newton-Raphson으로 MLE를 직접 계산했다.

모형	절편 β_0	$\beta_{\text{이자보상}}$	$\beta_{\text{차입금의존}}$	비고
단변량 ① 이자보상배율 (IV 0.663)	3.115	1.000	–	절편 = ln(19,150/850)
단변량 ② 차입금의존도 (IV 0.560)	3.115	–	1.000	
나이브 베이즈 (합산)	3.115	1 (고정)	1 (고정)	WOE 상관 0.57 무시
다변량 로지스틱	3.118	**0.714**	**0.579**	중복 증거 약 30~40% 제거

셀 (이자보상 구간, 차입금의존 구간)	기업 수	실제 부도율	나이브 베이즈 PD	로지스틱 PD
최악 (<1배, 의존도 상위)	2,028	13.86%	22.82%	13.27%
중간 (3구간, 중간)	3,116	3.11%	2.51%	2.96%
최우량 (≥최상위, 의존도 하위)	1,846	0.33%	0.19%	0.55%
포트폴리오 평균	20,000	4.25%	5.34%	4.25%*

* 절편이 있는 로지스틱 MLE에서는 Σ(y−p)=0이 성립하므로 평균 PD가 실제 부도율과 같아진다. 나이브 베이즈는 양 극단을 과장한다. 최악 셀은 실제보다 1.6배 높게, 최우량 셀은 0.6배로 낮게 예측해 평균 PD가 1.1%p 부풀었다. 등급별 PD가 이렇게 왜곡되면 IRB 은행에서는 RWA 왜곡으로 이어진다.

4.3 계수 → 스코어카드 배점

$$\text{Score} = \text{Offset} + \text{Factor} \times \ln(\text{odds}_{G:B}),\quad \text{Factor} = \text{PDO}/\ln 2,\quad \text{Offset} = \text{Score}_{\text{기준}} - \text{Factor} \times \ln(\text{odds}_{\text{기준}})$$

가정: 600점 ↔ odds 50:1, PDO 20 → Factor = 20/0.6931 = 28.854, Offset = 600 − 28.854×ln50 = 487.12

기본점 = Offset + Factor×β_0 = 487.12 + 28.854×3.118 = 577.1

구간 배점 = Factor × β_j × WOE_{ij}

이자보상배율 구간	1 (최저)	2	3	4	5 (최고)
WOE / 배점	−1.059 / −21.8	−0.207 / −4.3	0.420 / +8.7	0.959 / +19.8	1.913 / +39.4
차입금의존도 구간	1 (높음)	2	3 (낮음)		
WOE / 배점	−0.837 / −14.0	0.123 / +2.0	1.231 / +20.6		

최악 기업은 577.1−21.8−14.0 = 541.3점, 최우량 기업은 577.1+39.4+20.6 = 637.1점이다. 같은 이자보상배율 구간 차이(1→5)라도 β=1이었다면 배점 폭이 85.8점이었는데 실제로는 61.2점이다. **β가 배점 폭을 직접 줄이는 장치**라는 점이 보고서 표에서 바로 드러난다.

5. 실무 함정과 오해

1. **WOE 부호 규약 혼동:** ln(%G/%B)를 쓰면 β>0이 정상이고, ln(%B/%G)(부도를 1로 두는 SAS·일부 패키지)를 쓰면 β>0이어도 배점 방향이 반대가 된다. 검증 시 "음수 계수"를 지적하기 전에 규약부터 확인한다.
2. **"IV가 높으면 다변량에서도 중요하다"는 오해:** IV는 단변량 발산이다. IV 0.4짜리 두 변수가 서로 상관 0.8이면 둘째 변수의 β는 0 근처까지 떨어질 수 있다. 변수선정은 IV 필터 → 상관/VIF·변수 군집화 → 다변량 단계선택 순서로 진행한다.
3. **음(−)의 계수 방치:** WOE 모형에서 β<0이면 "이자보상배율이 좋을수록 감점" 같은 배점이 생긴다. 억제효과는 표본이 바뀌면 사라지기 쉽고 설명도 안 되므로, 변수를 제거하거나 구간을 합친 뒤 다시 적합한다.
4. **0 셀과 과세분화:** 불량이 0인 구간은 WOE가 무한대가 된다. 구간당 불량 수를 충분히 확보하고(실무상 구간 표본의 5% 이상 + 최소 불량 건수), 필요하면 +0.5 평활을 적용한다. 구간을 잘게 나누면 IV가 기계적으로 커진다.

5. **WOE 누수:** WOE를 전체 표본(검증 표본 포함)으로 계산하면 검증 AUC가 낙관적으로 나온다. WOE는 개발 표본에서만 산출해서 검증·운영 표본에 고정 적용한다.
6. **오버샘플링과 절편:** 부도를 오버샘플링하면 클래스 내부 분포 f(x|G), f(x|B)가 그대로이므로 WOE와 β는 변하지 않고 ln(G/B), 즉 절편만 바뀐다. 실제 부도율로 보정할 때는 절편에 $\ln[(\pi_G/\pi_B)/(G_s/B_s)]$를 더한다(π: 모집단 비율, s: 표본).
7. **세분화 모형 간 WOE 재사용:** 외감·비외감·개인사업자는 우량·불량 분포가 다르므로 WOE를 세그먼트별로 다시 산출해야 한다. 같은 구간표를 쓰면 각 세그먼트의 β가 1에서 크게 벗어난다.
8. **모형 비교 시 자유도:** WOE 변수는 계수가 1개지만 구간화 단계에서 이미 목표변수를 사용했다. 따라서 더미 코딩 모형과 AIC/SBC를 비교할 때 자유도를 과소 계산하게 된다(Lund 2016).

6. 현직자 수준 점검 질문과 모범 답안

Q1. (리스크관리부) WOE 변수 하나로 로지스틱을 돌리면 계수가 항상 1이 나옵니다. 그럼 회귀를 돌리는 의미가 있습니까?

A. 단일 변수에서 β=1은 베이즈 정리에서 나오는 항등식이라 회귀가 새로 알려주는 것이 없습니다. 회귀가 쓸모 있는 것은 다변량일 때입니다. 변수 간 중복 증거를 β<1로 줄여서 나이브 합산이 극단 등급의 PD를 과장하는 문제를 고칩니다. 예제에서 최악 셀 PD가 22.8%에서 13.3%로 실제(13.9%)에 가까워졌습니다.

Q2. (모형위원회) 이자보상배율 IV가 가장 높은데 최종 계수가 가장 작습니다. 변수가 잘못된 것 아닙니까?

A. IV는 단독으로 쓸 때의 변별력이고, β는 다른 변수를 통제한 뒤 남는 증거의 비율입니다. 이자보상배율은 영업이익률·차입금의존도와 같은 기업체력 요인을 공유하므로 β가 작게 나오는 것은 자연스럽습니다. 다만 β가 0.2 아래로 떨어지면 배점 기여가 미미해지니 해당 변수를 빼거나 변수 군집을 다시 정리하는 방안을 함께 제시합니다.

Q3. (검증팀) 부도 표본을 1:1로 오버샘플링했는데 WOE를 다시 계산해야 합니까?

A. 클래스 내부에서 무작위로 추출했다면 %G, %B 분포가 기댓값 기준으로 변하지 않으므로 WOE와 β도 바뀌지 않습니다. 바뀌는 것은 절편 ln(G/B)뿐이므로 실제 부도율 기준의 사전 오즈로 절편을 보정하면 됩니다. 단, 층화 기준(업종·규모)이 바뀌었다면 WOE를 다시 산출해야 합니다.

Q4. (여신심사부) IV와 PSI가 같은 식이라던데 무슨 뜻입니까?

A. 둘 다 $\Sigma(p-q)\ln(p/q)$, 즉 대칭 KL 발산입니다. IV는 우량과 불량 분포를 비교해서 "변별력"을 재고, PSI는 개발 시점과 운영 시점 분포를 비교해서 "안정성"을 잽니다. 그래서 구간 수와 표본 크기에 민감하다는 약점도 똑같습니다. 0.1/0.25 같은 임계값을 쓸 때는 구간 수를 함께 표기해야 비교가 공정합니다.

Q5. (모형개발 실무자) ML(XGBoost)을 쓰면 WOE가 필요 없지 않습니까?

A. 트리 모형은 구간화를 내부에서 하므로 성능만 보면 WOE가 필수는 아닙니다. 그래도 WOE+로지스틱은 배점표 형태로 바로 바꿀 수 있고(β×WOE×Factor), 단조성을 강제할 수 있으며, 변수별 기여를 로그오즈 단위로 합산해서 보여줄 수 있습니다. 감독 대응과 오버라이드 관리에서 이 장점이 큽니다. ML 모형을 벤치마크(챌린저)로 두고 성능 차이를 정량화하는 구성이 현실적입니다.

7. 컨설팅 실무 시사점

- **개발 보고서 표 구성:** 변수선정표에 IV와 함께 "단변량 β(=1) 대비 다변량 β"를 같이 보여준다. $1-\beta_j$를 "중복 정보 비율"로 해석해 주면 모형위원회의 계수 질문 대부분을 미리 해소할 수 있다.
- **현행 모형 진단 제안:** 고객 은행 기존 스코어카드에서 (a) 음의 계수, (b) β<0.2인 변수, (c) 극단 등급의 실제 부도율 대비 PD 과장 여부를 점검한다. 이 세 가지가 보이면 나이브 합산형 구조이거나 공선성이 방치된 것이다. (c)는 등급별 PD를 거쳐 IRB RWA나 IFRS9 충당금에 직접 연결되므로 "모형 개선의 재무효과"를 설명하는 근거가 된다.
- **재무변수 군집화 → 대표변수 선택:** 수익성·안정성·활동성·현금흐름 군집에서 군집별 1~2개를 뽑는 방식이 β를 1 근처로 유지하는 가장 실용적인 방법이다. NICE 재무DB의 비율 다수가 같은 분자나 분모를 공유한다는 점(영업이익, 차입금)을 근거로 든다.
- **세분화·표본 설계 근거:** 외감·비외감별 WOE 재산출과, 오버샘플링 시 절편 보정식을 개발 방법론서에 명시한다. 검증 단계의 "WOE 누수" 지적을 미리 막을 수 있다.

8. 참고자료

- Lund, B. (2016). "Finding and Evaluating Multiple Candidate Models for Logistic Regression", MWSUG 2016 AA15. WOE 단일 변수 β=1, 절편=log(G/B), 자유도 문제. mwsug.org/proceedings/2016/AA/MWSUG-2016-AA15.pdf
- Lund, B. (2021). SAS Global Forum paper 1022. WOE 사용 문헌 정리(Siddiqi, Finlay, Thomas).
- Larsen, K. (2015). "Data Exploration with Weight of Evidence and Information Value in R", Stitch Fix Tech Blog. 나이브 베이즈/semi-naive 해석.
- Sudjianto, A. & Burakov, D. (2025). "An Information-Theoretic Framework for Credit Risk Modeling", arXiv:2509.09855. IV=Jeffreys divergence=PSI 동일성, IV 표준오차.
- Rojas & Alvarez, arXiv:2309.13183. J-divergence 기반 IV 검정.
- Zeng, G. (2013). "Metric Divergence Measures and Information Value in Credit Scoring", Journal of Mathematics.
- de Jongh & Webster (Standard Bank), "The Impact of Multicollinearity on the Variation of Coefficient Estimation When Using Logistic Regression", Credit Scoring & Credit Control Conference.
- Siddiqi, N. Credit Risk Scorecards (Wiley). IV 해석 기준과 Factor/Offset 배점 체계. 원문은 직접 확인하지 못했고, 검색된 2차 자료(toad 문서, R scorecard 패키지 소스)에서 수식을 교차 확인함.
- toad 문서(toad.readthedocs.io): Factor=PDO/ln2, Offset 예시(600점·50:1·PDO20 → 487.12+28.85·ln odds)로 4.3절 수치를 검산함.
- 4.1·4.2절 수치는 모두 가상 데이터이며, 순수 Python Newton-Raphson으로 직접 계산함. "구간당 불량 비중 5%" 등 구간화 기준은 업계 관행이며 규정 수치가 아님.